

DALAS – Examen réparti – 13/05/24 – 20 pts

Durée : 1h30 - Documents non autorisés. Calculatrices autorisées

Exercice 1 (4 points) – Questions de cours et QCM**Q 1.1 QCM**

Questions	Réponses
1. Quelle représentation graphique permet d'afficher la distribution des variables continues ?	☐ A- Camembert ☐ B- Histogramme ☐ C- Diagramme en barre ☐ D- Nuage de points
2. Quelle mesure de centralité est représentée par la hauteur des boîtes à moustaches ?	☐ A- Moyenne ☐ B- Médiane ☐ C- Mode ☐ D- Variance
3. Quelle visualisation est utilisée pour identifier les points aberrants (outliers) dans un jeu de données ?	☐ A- Boîte à moustache ☐ B- Histogramme ☐ C- Diagramme en barre ☐ D- Nuage de points
4. Quel est le but d'une matrice de corrélation ?	☐ A- Visualiser la distribution des données ☐ B- Afficher les relations entre variables ☐ C- Identifier les données manquantes ☐ D- Fournir les statistiques des données
5. Quelle visualisation est utilisée pour visualiser la relation entre une variable catégorielle et continue ?	☐ A- Boîte à moustache ☐ B- Histogramme ☐ C- Diagramme en barre ☐ D- Nuage de points
6. Quel est l'objectif du mode ?	☐ A- Valeur la plus fréquence ☐ B- Valeur moyenne ☐ C- Dispersion des données ☐ D- Présence de valeurs aberrantes

Q 1.2 Quelles sont les bibliothèques python utilisées pour l'EDA. Décrire leurs principaux objectifs.**Q 1.3** Quelles sont les stratégies d'analyse liées à l'importance des caractéristiques ?**Exercice 2 (7 points) – EDA : Méthodes d'enseignement**

Un chercheur en sciences de l'éducation propose trois méthodes d'enseignement [metA, metB, metC]. Il se demande si celles-ci sont également efficaces et ceci pour des élèves ayant des niveaux différents de lecture fort, moyen ou faible. Puis, il réalise une épreuve et donne une note [score] à chaque élève. Les résultats sont consignés dans le tableau :

score	metA	metB	metC
fort	40	32	30
moyen	24	20	18
faible	22	20	18

Q 2.1 Réaliser une analyse exploratoire pour analyser ce tableau. Elle peut inclure des analyses descriptives, statistiques et visualisations simples.**Q 2.2** Rédiger un paragraphe synthétisant les conclusions que vous pouvez déduire de l'analyse exploratoire.**Q 2.3** Ce graphique est-il suffisant pour conclure à l'efficacité d'une méthode pédagogique ? Quelles analyses pourraient être rajoutées ?**Exercice 3 (4 points) – ACP : logement et prix**

On dispose d'un jeu de données qqui correspond au prix d'une maison (par m^2), dont les attributs sont :

- La date de la transaction (1 juin 2015 est transformé en 2015.5) avec une déviation standard $\sigma \approx 0,28$
- L'âge de la maison, avec $\sigma \approx 11,39$
- La distance à la prochaine station de métro (m) avec $\sigma \approx 1083,89$
- Le nombre de magasins à proximité avec $\sigma \approx 2,95$
- Latitude avec $\sigma_{lat} \approx 0,012$
- Longitude avec $\sigma_{lon} \approx 0,015$
- Le prix avec $\sigma \approx 13,6$

Nous souhaitons visualiser les données avec une ACP.

Q 3.1 Expliquez tout d'abord comment vous transformez les données pour obtenir une matrice X de taille individu $\times$ caractéristique (ordre similaire à la liste ci-dessus) qui puisse être utilisée pour calculer la matrice de covariance $\Sigma = \frac{1}{n} \sum X^T X$. Votre choix doit être **expliqué** (plusieurs bonnes réponses sont possibles).La décomposition de $\Sigma = U\Lambda U^T$ en valeurs propres nous donne (les caractéristiques suivent le même ordre que dans la question précédente) :

$$U = \begin{pmatrix} -0.00 & -0.09 & 0.96 & 0.22 & 0.01 & 0.10 & -0.06 \\ 0.04 & -0.95 & -0.08 & 0.08 & -0.01 & -0.29 & 0.03 \\ 0.51 & 0.02 & 0.11 & -0.27 & -0.08 & -0.02 & 0.81 \\ -0.42 & -0.15 & 0.02 & -0.27 & -0.76 & 0.38 & 0.10 \\ -0.40 & -0.17 & 0.07 & -0.54 & 0.63 & 0.31 & 0.14 \\ -0.44 & 0.03 & -0.14 & 0.68 & 0.13 & 0.14 & 0.54 \\ -0.46 & 0.20 & 0.16 & -0.22 & -0.08 & -0.80 & 0.16 \end{pmatrix} \quad \Lambda = \begin{pmatrix} 59.43 \\ 132.57 \\ 228.53 \\ 254.69 \\ 424.98 \\ 439.87 \\ 1350.93 \end{pmatrix}$$

Q 3.2 Quel est le premier axe et comment l'interprétez-vous ? En particulier, que vous pouvez vous dire sur le rapport entre le prix et les autres attributs ?

Q 3.3 Expliquer combien d'axes sont nécessaires pour obtenir une bonne couverture de la variance des données (80% environ) - vous pouvez faire un calcul très approximatif.

Exercice 4 (6 points) – Classification - Kaggle

Vous participez à un challenge de type Kaggle. Le problème est un problème de classification binaire. Vous disposez des données d'entraînement (avec caractéristiques et étiquettes) et des données sur lesquelles vous devez évaluer votre classifieur (sans les étiquettes). Vous devez soumettre pour ces dernière données, une liste d'étiquettes prédites par votre système. Vous avez la possibilité d'étudier la performance de plusieurs modèles.

Q 4.1 Discuter de la difficulté d'entraîner et d'évaluer un modèle de classification sur un tel jeu de données.

Q 4.2 Décrire le protocole d'évaluation (jeu de données, métriques, ...) que vous souhaitez mettre en place pour apprendre et évaluer les modèles cités précédemment. Conseil : distinguer ces deux étapes (entraînement et évaluation) dans votre protocole.

Q 4.3 Comment identifier le meilleur modèle à présenter au challenge Kaggle ?