

Examen ML - DAC

2 heures - Barème indicatif - Document : 2 feuilles A4

Exercice 1 (4 points) – P'têt ben qu'oui

Donner vos réponses, **sans justifier**, sous la forme 1-V par exemple si l'affirmation 1 est vraie, 1-F si l'affirmation est fautive. Chaque bonne réponse apporte 0.25 points, chaque mauvaise retire 0.25 points à votre note (ou moins, barème indicatif).

1. Si l'on était capable de définir un maillage infiniment petit, la méthode des histogrammes permettrait d'estimer parfaitement la densité d'une variable aléatoire à partir de réalisations observées.
2. La rétro-propagation permet d'apprendre un optimum global d'un réseau de neurones
3. Il est possible de multiplier deux noyaux admissibles pour former une nouvelle fonction noyau.
4. La fonction $k(x, x') = \max(0, x - x')$ est un noyau.
5. Pour le boosting, à une itération donnée, tous les poids des exemples mal classés sont augmentés du même facteur multiplicatif.
6. Il est nécessaire de normaliser les données lorsqu'on apprend un arbre de décision.
7. L'algorithme du Boosting correspond à agréger avec une pondération différents classifieurs faibles appris indépendamment sur le jeu de données.
8. La somme de deux noyaux admissibles est un noyau admissible si et seulement si les projections sous-jacentes sont dans le même espace.
9. La somme de deux variables aléatoires gaussiennes suit une loi gaussienne seulement si elles ont la même espérance.
10. Une matrice de covariance diagonale implique forcément l'indépendance des dimensions deux à deux.
11. Il existe des noyaux qui ne sont pas des produits scalaires de projections en dimension finie.
12. En RL, lorsque le MDP est parfaitement connu, il est possible de trouver la politique optimale sans exploration.
13. Les politiques trouvées par Policy-iteration sont meilleures que celles par Value-iteration
14. L'algorithme t-SNE est bien adapté pour construire des clusters significatifs.
15. Il n'est pas possible d'utiliser le kernel trick noyaux pour la régression linéaire.
16. On appelle bruit gaussien une perturbation des étiquettes qui suit une loi normale dont l'espérance dépend des données.

Exercice 2 (4 points) – Le noyau c'est la norme

On suppose les points suivants dans $\mathbb{R}^2$: $\{(0.2, 0.4), (0.4, 0.8), (0.4, 0.2), (0.8, 0.4), (0, 0.4), (0.4, 0)\}$ tous de la classe 1, et $\{(0.4, 0.4), (0.8, 0.8)\}$ de la classe -1. On considère le noyau suivant : $k(\mathbf{x}, \mathbf{x}') = \frac{\langle \mathbf{x}, \mathbf{x}' \rangle}{\|\mathbf{x}\| \|\mathbf{x}'\|}$.

Q 2.1 A quelle fonction de projection $\phi(\mathbf{x})$ correspond ce noyau ?

Q 2.2 Dessiner les points dans le plan. Pour chaque point $\mathbf{x}_i$, représenter le point projeté $\phi(\mathbf{x}_i)$. Dessiner la séparatrice linéaire dans l'espace projeté. Indiquer les vecteurs supports.

Q 2.3 Dessiner la séparatrice correspondante dans l'espace initial et justifier votre réponse.

Q 2.4 Est-il possible d'apprendre cette séparatrice avec un perceptron ? Justifier.

Exercice 3 (6 points) – Une trace de gradient

On considère un problème de regression sur un jeu de données $S = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^N$ avec $\mathbf{x}^{(i)} \in \mathbb{R}^d$ et $y^{(i)} \in \mathbb{R}$.

On considère le modèle suivant pour la regression : $f_{\theta}(\mathbf{x}) = \sum_{j=1}^p (\theta^j)^T (\mathbf{x})^j$, composé des p paramètres $\theta^j \in \mathbb{R}^d$.

L'opération $(\mathbf{x})^j$ consiste à l'exponentiation terme à terme du vecteur $\mathbf{x}$ (chaque terme du vecteur est mis à la puissance j , à ne pas confondre avec le i -ème exemple $\mathbf{x}^{(i)}$). On considère le coût MSE classique suivant

$$J(\theta) = \frac{1}{2} \sum_{i=1}^N w^{(i)} \left(\sum_{j=1}^p (\theta^j)^T (\mathbf{x}^{(i)})^j - y^{(i)} \right)^2 \text{ où les } w^{(i)} \text{ représentent le poids de chaque exemple.}$$

Q 3.1 Montrez que l'erreur peut se mettre sous la forme $J(\theta) = \frac{1}{2} \text{tr} [(X\Theta - Y)^T W (X\Theta - Y)]$. Donnez le contenu exacte et les dimensions des matrices X, Θ, W, Y .

Q 3.2 Soit $\Theta \in \mathbb{R}^{M \times 1}$ et $\Gamma \in \mathbb{R}^{M_0 \times M}$ et un terme de coût $P(\Theta) = \frac{1}{2} \sum_{i=1}^{M_0} (\Gamma\Theta)_i^2$ que l'on ajoute à la fonction de coût précédente. Montrez que $P(\Theta)$ peut s'écrire de la manière suivante : $P(\Theta) = \frac{1}{2} \text{tr} ((\Gamma\Theta)^T (\Gamma\Theta)) = \frac{1}{2} \|\Gamma\Theta\|_2^2$.

Q 3.3 Le coût étudié est donc : $J(\Theta) = \frac{1}{2} \text{tr} [(X\Theta - Y)^T W (X\Theta - Y)] + \frac{1}{2} \text{tr} ((\Gamma\Theta)^T (\Gamma\Theta))$. Trouvez le Θ qui minimise ce coût.

Vous pouvez utiliser les résultats suivants : $\nabla_X \text{tr}(AX) = A^T$ et $\nabla_X \text{tr}(AX^T BXC) = B^T X^T A^T C^T + BXC A$.

Q 3.4 Si on souhaite minimiser l'erreur en apprentissage, quelle est la valeur optimale de Γ ? Si au contraire on souhaite minimiser l'erreur en test, quelle est la valeur optimale de Γ ?

Exercice 4 (6 points) – I get around

Soit un ensemble de données $\mathcal{D} = \{\mathbf{x}^i \in \mathbb{R}^d\}_{i=1}^n$. On souhaite construire une sphère dans $\mathbb{R}^d$ telle qu'elle contienne la majorité des points de $\mathcal{D}$ mais qu'elle soit également de rayon minimal. On notera $C \in \mathbb{R}^d$ le centre de la sphère et $R \in \mathbb{R}$ le rayon de la sphère. On propose d'étudier le problème de minimisation suivant pour résoudre ce problème :

$$\min_{C, R, \xi_i} R^2 + \lambda \sum_{i=1}^n \xi_i^2 \text{ tq. } \|\mathbf{x}^i - C\|^2 \leq R^2 + \xi_i \quad \forall i = 1, \dots, n$$

Rappel : Pour un problème d'optimisation $\min_{\theta \in \mathbb{R}^d} J(\theta)$ sous les m contraintes $g_j(\theta) \leq 0$ pour $j = 1 \dots m$, le Lagrangien associé est $\mathcal{L}(\theta, \mu) = J(\theta) + \sum_{j=1}^m \mu_j g_j(\theta)$ avec $\mu_j \geq 0$. Les conditions KKT spécifient qu'à l'optimum, nécessairement $\nabla \mathcal{L}(\theta, \mu) = 0$, $g_j(\theta) \leq 0$, $\mu_j \geq 0$, et $\mu_j g_j(\theta) = 0$ pour $j = 1 \dots m$.

Q 4.1 En considérant chaque terme du problème d'optimisation, expliquez en quoi cette formulation répond bien au problème. À quoi sert λ ?

Q 4.2 Donner le Lagrangien correspondant à ce problème d'optimisation.

Q 4.3 Écrire les conditions d'optimalité par rapport aux variables C, R, ξ_i et en déduire l'expression du centre de la sphère.

Q 4.4 Quel est le problème dual correspondant?

Q 4.5 Discuter de la position d'un point $\mathbf{x}^i$ en fonction de la valeur de son coefficient α_i .

Q 4.6 Connaissant la solution du problème dual, comment calculer R ?

Q 4.7 Quelle(s) application(s) vous voyez à ce problème?

Exercice 5 (4 points) – Catch me if you can

Examen ML - DAC

2 heures - Barème indicatif - Document : 2 feuilles A4

Exercice 1 (4 points) – P'têt ben qu'oui

Donner vos réponses, **sans justifier**, sous la forme 1-V par exemple si l'affirmation 1 est vraie, 1-F si l'affirmation est fausse. Chaque bonne réponse apporte 0.25 points, chaque mauvaise retire 0.25 points à votre note (ou moins, barème indicatif).

1. Si l'on était capable de définir un maillage infiniment petit, la méthode des histogrammes permettrait d'estimer parfaitement la densité d'une variable aléatoire à partir de réalisations observées.
2. La rétro-propagation permet d'apprendre un optimum global d'un réseau de neurones
3. Il est possible de multiplier deux noyaux admissibles pour former une nouvelle fonction noyau.
4. La fonction $k(x, x') = \max(0, x - x')$ est un noyau.
5. Pour le boosting, à une itération donnée, tous les poids des exemples mal classés sont augmentés du même facteur multiplicatif.
6. Il est nécessaire de normaliser les données lorsqu'on apprend un arbre de décision.
7. L'algorithme du Boosting correspond à agréger avec une pondération différents classifieurs faibles appris indépendamment sur le jeu de données.
8. La somme de deux noyaux admissibles est un noyau admissible si et seulement si les projections sous-jacentes sont dans le même espace.
9. La somme de deux variables aléatoires gaussiennes suit une loi gaussienne seulement si elles ont la même espérance.
10. Une matrice de covariance diagonale implique forcément l'indépendance des dimensions deux à deux.
11. Il existe des noyaux qui ne sont pas des produits scalaires de projections en dimension finie.
12. En RL, lorsque le MDP est parfaitement connu, il est possible de trouver la politique optimale sans exploration.
13. Les politiques trouvées par Policy-iteration sont meilleures que celles par Value-iteration
14. L'algorithme t-SNE est bien adapté pour construire des clusters significatifs.
15. Il n'est pas possible d'utiliser le kernel trick noyaux pour la régression linéaire.
16. On appelle bruit gaussien une perturbation des étiquettes qui suit une loi normale dont l'espérance dépend des données.

Exercice 2 (4 points) – Le noyau c'est la norme

On suppose les points suivants dans $\mathbb{R}^2$: $\{(0.2, 0.4), (0.4, 0.8), (0.4, 0.2), (0.8, 0.4), (0, 0.4), (0.4, 0)\}$ tous de la classe 1, et $\{(0.4, 0.4), (0.8, 0.8)\}$ de la classe -1. On considère le noyau suivant : $k(\mathbf{x}, \mathbf{x}') = \frac{\langle \mathbf{x}, \mathbf{x}' \rangle}{\|\mathbf{x}\| \|\mathbf{x}'\|}$.

Q 2.1 A quelle fonction de projection $\phi(\mathbf{x})$ correspond ce noyau ?

Q 2.2 Dessiner les points dans le plan. Pour chaque point $\mathbf{x}_i$, représenter le point projeté $\phi(\mathbf{x}_i)$. Dessiner la séparatrice linéaire dans l'espace projeté. Indiquer les vecteurs supports.

Q 2.3 Dessiner la séparatrice correspondante dans l'espace initial et justifier votre réponse.

Q 2.4 Est-il possible d'apprendre cette séparatrice avec un perceptron ? Justifier.

Exercice 3 (6 points) – Une trace de gradient

On considère un problème de regression sur un jeu de données $S = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^N$ avec $\mathbf{x}^{(i)} \in \mathbb{R}^d$ et $y^{(i)} \in \mathbb{R}$.

On considère le modèle suivant pour la regression : $f_{\theta}(\mathbf{x}) = \sum_{j=1}^p (\theta^j)^T (\mathbf{x})^j$, composé des p paramètres $\theta^j \in \mathbb{R}^d$.