

Cours

Charles Vin

Date

1 Généralité

Le fossé sémantique, ou "semantic gap", désigne l'écart entre les représentations de bas niveau des données (par exemple, les caractéristiques syntaxiques ou les mots individuels) et les représentations de haut niveau (par exemple, la signification ou le contexte) qui sont plus proches de la compréhension humaine.

Métrique Voir la fiche RI pour : métrique, zipf law, tf-idf

Problème d'équilibre des classes

- Accuracy poubelle → Utiliser les autres metrics : AUC / ROC
- Ré-équilibrer le jeu de données : supprimer des données dans la classe majoritaire
- Fonction de coût : pénaliser plus les erreurs dans la classe minoritaire (cours 1 diapo 51)

Problème de dimension Ajouter un terme sur la fonction coût (ou vraisemblance) pour pénaliser le nombre (ou le poids) des coefficients utilisés pour la décision. (Cours 1 diapo 50)

TF-IDF encoding if word k is in most documents, it is probably useless → TF-Idf encoding : Donne plus de poids au keyword et un petit peu moins au stopword. A combiner avec blacklist. Plus d'info dans la fiche RI

2 Liste des pré-processing

2.1 Noisy entity removal

- Punctuation, capital/lower case
- Stop word
- Rare word (less than a threshold)

2.2 Text Normalization

- Lemmatization : Lions → Lion, are → be
- Stemming

2.3 Word standardisation

Regular expression, e.g. for removing "." or expanding words' contractions ("I'll" → "I will")

3 Bag of Word

3.1 Strengths and drawbacks

- Avantage :
- Easy light fast

- Opportunity to enrich (Context encoding, Part Of Speech)
- Efficient implementation
- Still very effective with classification
- Simple à mettre en œuvre, facile à interpréter, conserve la fréquence des mots.

Limite :

- Ne capture pas l'ordre des mots, génère des vecteurs de grande taille, peut être sensible au bruit.
- Loose document / sentence structure : mitigated with N-gram
- Several task missing : POS tagging, text generation
- Semantic gap : On peut pas utiliser la distance euclidienne pour mesurer la différence sémantique

Représentation en tri-grammes de lettres :

Avantages : Capture les motifs locaux et les sous-chaînes fréquentes, réduit la taille du vocabulaire, résilient aux fautes d'orthographe. capturer des motifs spécifiques à un auteur.

Inconvénients : Peut générer du bruit, perd la signification des mots complets, moins interprétable.

3.2 Classification

Naive Bayes Rapide, interprétable, naturellement multiclasse. Perf à améliorer. Bien filtrer les stop word. Extension par robustesse (?)

Classifieur linéaire Scalable, attention sensible au dimension

4 Apprendre la sémantique

- Première approche : WordNet : trop statique (nouvelle expression, hashtag, vocab technique) et fait à la main
- Deuxième approche : Mesure de co-occurrence : "Fair **and** legitimate", "Fair **but** brutal" → Marche bien + combo avec BoW

5 Unsupervised approaches

5.1 LSA : Latent Semantic Analysis

But : réduire la dimension, réduire le bruit. Hyperparamètres : Nombre de sujets, hyperparamètres de la distribution de Dirichlet On un un vocabulaire de taille d , N document, une LSA avec k plus grande valeur propre, qui forme k grand "concept" du corpus.

On décompose la matrice des occurrence $X \in \mathbb{Q}^{N \times d}$ en

- $U \in \mathbb{R}^{k \times d}$: une ligne de U représente un vecteur de poids par mot dans chacun des k concept.
- $\Sigma \in \mathbb{R}^{k \times k}$ valeur propre → **Tri par ordre croissant** pour garder les k plus grande valeur (comme en BIMA)
- $V \in \mathbb{R}^{d \times k}$ Une colonne de V représente l'intensité des relations entre le document j et chaque concept
- Est-ce que V et U sont pareil??
- Comment on classif un nouveau document la dedans? Soit q un nouveau document ou une query, $\hat{q} = \sigma^{-1} U^{-1} q$

Un ligne de la matrice de la matrice d'ocurrence t_i , une colonne d_i . $t_i^T t_p$ corrélation de ces deux terme sur tout le corpus → $X X^T$. $d_j^T d_q$ corrélation entre ces deux document pour tout terme → $X^T X$

5.1.1 Stength and drawbacks

- Bon combo avec t-SNE.
- Entièrement basé sur BoW : même problème plus +
 - Not robust to stop word (=high singular values)
 - Problème forme négative
- Problème avec les mots rare dans les petits corpus (?)
- Peu combiner des dimension qui non pas de lien entre elle (combiner linéairement voiture et camion ok mais pas voiture et bouteille)

- Mauvaise prise en compte des doubles sens des mots, car un mot = un point de l'espace sémantique

5.2 Kmean

Comme d'hab, à combo avec LSA pour réduire les dimensions.

5.3 Dérivé LSA

- P-LSA : K-mean mais avec un assignement soft mesurer par la probabilité
- LDA : On rajoute un prior : modèle plus complexe → Les méthodes EM → on utilise MCMC pour estimer les vraisemblance
- D'autre extension bien complexe

6 Word Embeddings & Neural network

Word that appear in similar contexts in text tend to have similar meanings

6.1 Words2Vec

Apprendre des représentations vectorielles des mots (word embeddings) en exploitant les relations contextuelles entre les mots. Implémentation de l'idée précédente : Modèle auto-supervisé, input OH encoding; + backpropagation

- Réseau de neurone peu profond pour :
- CBoW : Predict surrounding words (context) from central word; work well for frequent words
- Skipgram : Predict context from central word; work well for rare words

On note :

- Soft max en sortie sur $|V|$ (taille du vocab) valeur → Lourde → Evitable par négative sampling je crois??
- Analogie dans l'espace latent H : Féminin/Masculin, Capitale, sémantique
- **Difficulté pour aller au delà des mots** : Comment encoder une phrase entière dans H → moyenne, sommes, min, max
- Hyperparamètres : Taille du vecteur, fenêtre contextuelle, nombre d'itérations, taux d'apprentissage.

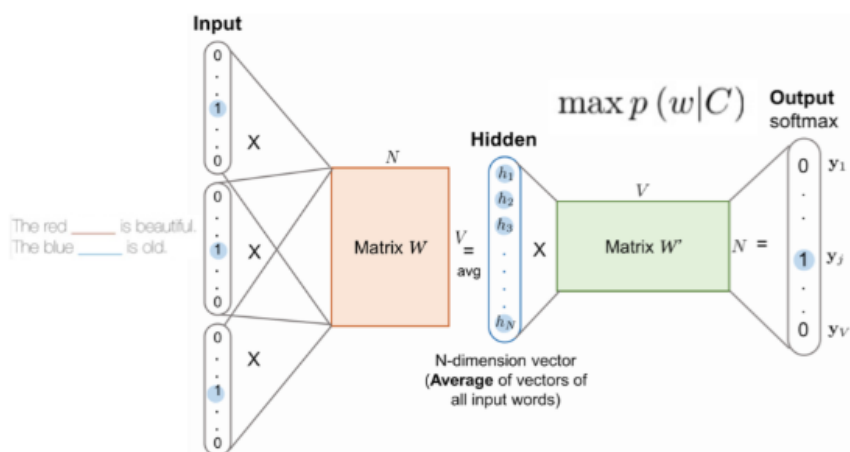


Figure 1 – CBoW

6.1.1 Glove

- Input : matrice de co-occurrence + accès aux word embedding

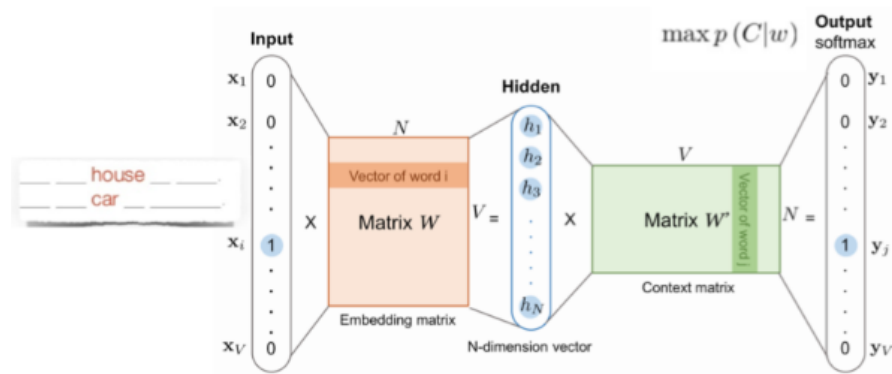


Figure 2 – Skip-Gram

- On veut explicitement que la proximité dans l'espace latent représente la co-occurrence des mots
- Fonction de coût et de prédiction de GloVe \approx PLSA (espace latent pour les co-occurrences) + Contexte local + les words embedding

6.2 Neural Networks

6.2.1 CNN

How to scale/classify with Word Embedding? → Convolutional Neural networks

1. Latent représentation of the word
2. Couche de convolution
3. → Une représentation d'un document dans une dimension fixe
4. → Classification : Régression, NN w/ soft max, ...

+ une back propagation sur la layer de convolution, l'espace de représentation latent.

Problème : 2 mois de train

6.2.2 RNNs

- Code des séquences **entière** => parfait pour du texte
- Forme de mémoire du passé dans le réseau
- Problème de profondeur et d'évanouissement du gradient

3 types de classification :

- One to many : Image captioning (input une image, sortie plusieurs mots)
- Many to one : Sentiment classification, Question answering (how many ...)
- Many to many : Text generation, translation (input anglais sortie français), speech2text

Evolution :

- Architecture spéciale contre la disparition du gradient : LSTM, GRU == long term memory
- Bi-directionnal RNNs : incorporate information from words both preceding and following

Toujours problème d'évanouissement du gradient + goulot d'étranglement pour encoder tout une phrase

6.3 Attention model & Transformers

- Encode l'information globale (!= CNN que local)
- Matrice d'attention == encodage de
 - Chaque mot encodé avec Key, Query, Value
 - la similarité de chaque mot de la phrase
 - inclusion du contexte globale
- Multi-head attention : on stack en parallèle les self-attention layer + combinaison
- Perte de la position : Fully connected layers : permutation invariant → Encodage manuel

6.3.1 BERT

Comme word2vec avec de l'attention : pré-train pour apprendre l'espace latent → Fine tune sur other task.

Token de classe CLS t_0 qui représente la phrase entière dans un espace latent → utile pour prédire la classe avec des modèle classique (regression ect) → **Plus le problème de W2V avec la moyenne ou la somme**

6.3.2 Transformers Decoder

GPT

- Prédire le mot suivant en fonction du contexte.
- Masked Attention : hide (mask) information about future tokens from the model. On donne la phrase au fur et à mesure pour pas tout apprendre d'un coup. On peut pas utiliser les mots d'après vu qu'on génère