

# Fiche

## BD réparties

- Réutiliser les fragmentation précédente comme filtre avec les jointures
- Fragmentation horizontale : selection sur la table général ( $garage_v$  TD6-exo1)
- Fragmentation horizontale dérivé : réutilisation d'une fragmentation poru refaire une fragmentation
- Fragmentation disjointe : lorsqu'il y n'y a pas de répétition dans entre les fragments de cette table.

# TD6

## Exercice 1a

1.  
Soit  $v$  la ville du garage et  $id_{garage}$  sont id

- $Garage_v = \sigma_{ville=v}(Garage)$
- $Habilite_v = Habilite \bowtie Garage_v$
- $Mecanicien_v = Mecanicien \bowtie Garage_v$
- $Personne_v = Personne \bowtie Mecanicien_v$
- $Reparation_v = Reparation \bowtie Mecanicien_v$
- $Client_v = Client \bowtie Reparation_v$
- $Possede_v = Possede \bowtie Client_v$
- ~~$Tarif_v = Tarif \bowtie Reparation_v$~~   $Tarif_v = Tarif$  répliqué dans toute les villes

2.  
Pas disjoint si un client vas dans plusieurs ville ? Dans la correction de mathilde y'on dit que  $possede_v$  et les fragment dérivé sont non disjoint ??

3.  
Facile, on fait la même chose mais avec

- $Habilite_m = \sigma_m(Habilite)$
- $Garage_m = Garage \bowtie Habilite_m$

## Exercice 1b

1. On veut les marque des voiture ayant subit une réparation de moins de 100€ et avec une immatriculation < 6000
2. Version brutforce  $\sigma_{prix < 100 \wedge immat < 6000}((Reparation \bowtie_{intervention} Tarif) \bowtie_{immat} Possede)$   
Version qui suit la consigne  $\sigma_{prix < 100}(Tarif) \bowtie \sigma_{immat < 6000}(Possede) \bowtie Reparation$
3.  $\sigma_{prix < 100}(Tarif_{S1}) \bowtie \sigma_{immat < 6000}(Possede_{S1}) \bowtie Reparation_{S1}$  Wouah compliqué compliqué la correction alors que c'était évident
4. C'était dire qu'on utilisait que le S1 car on a pas de donnée correspondant à nos filtre en S2
5. Aucune donnée transféré car on peut tout faire en S1. Efficace

# TD7

## Exercice 4 page 4 (ER2-19)

1.  $P(R) = \frac{card(R)}{T_{page}/largeur(R)} = \frac{card(R)}{a} \Leftrightarrow card(R) = P(R) * T_{page}/largeur(R)$

Taille d'un tuple de  $R_1 : t(R_1) = 2 * 10 = 20$  octet

- $card(R_1) = 10000 * 4000/20 = 10000 * 200 = 2 * 10^6$
- $card(R_1 \bowtie R_2) = card(R_2) * \frac{card(R_1)}{nbValDistinctDeADansR_1} = card(R_2) = 2 * 10^7$  car  $R_2$  beaucoup plus grand que  $R_1$  donc

2.  $P(T) = card(R_1 \bowtie R_2) * \frac{largeur(T)}{T_{page}} = 2 * 10^7 * \frac{30}{4000} = 150000 ;$

$P(Q) = card(Q) * \frac{40}{4000} = card(T) * 1/100 = 2 * 10^5$

3. Par Hashage

1. Pas de transfert, jointure par hachage externe, avec  $R_2$  et  $R_1$  qui ne tiennent pas en mémoire avec  $K = 200, cout(R_1 \bowtie R_2) = 2 \lfloor \log_K(P(R_1)) \rfloor (P(R_1) + P(R_2)) + P(R) + P(R_2) = P(R_1) * t_{io} + P(R_2) * t_{io} = 110000t_{io}$
2. Transfert de  $P(T) = 2 * 10^7$  pages sur S3 :  $cout = 150000t_s$
3. Calcul de  $Q$  sur S3 :  $cout(Q) = (P(T) + P(R_3))t_{io} = 160000t_{io}$
4. Transfert de  $Q$  sur S1 :  $cout = P(Q)t_s = 200000t_s$
5. Finalement :  $110000t_{io} + 160000t_{io} + 150000t_s + 200000t_s = 270000t_{io} + 350000t_s$   
=> J'ai faux **je comprends rien à la correction**

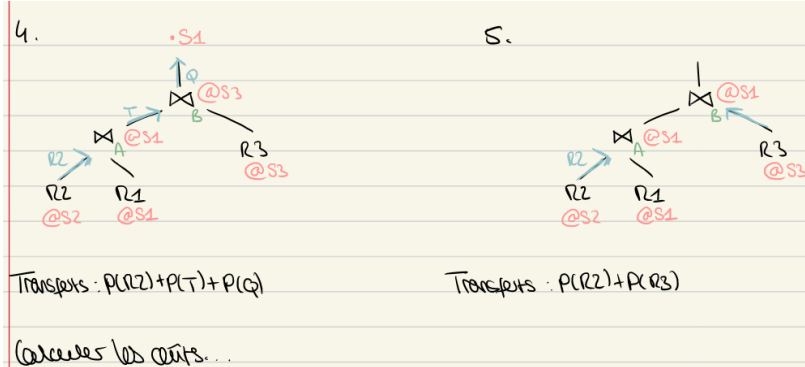
Pourquoi on doit se fix des blocs comme ça ? Pourquoi on divise par 50 pour R2 ? Pourquoi on utilise pas la formule du cout par hachage externe ? Qui ne peux mathématiquement pas donner un 3 pour le premier coût

Correction : Par hashage \* On veut  $Cout(T)$  par hachage mais ni R1 ni R2 ne tiennent en mémoire (mémoire de 201) \* **Lire** R1 par blocs de 200 pages : on a  $\frac{10000}{200} = 50$  blocs \* On veut répartir les données de R1 en 50 paquets de 200 pages en utilisant une fonction de hachage  $h \rightarrow P(R1)$  écritures pour répartir R1 \* Lire R2 par blocs de 200 pages pour la répartir en fonction de  $h$ . Remarque : les paquets de T2 font  $\frac{100000}{50} = 2000$  pages  $\rightarrow$  P(R2) écritures \* Jointure entre les paires de paquets ayant le numéro de paquet  $\rightarrow P(R1) + P(R2) * Total : cout(T) = 3P(R1) + 3P(R2)$

Correction : Par tri fusion \* Lire et trier R1 en 50 blocs de 200 pages :  $2P(R1) * Lire$  et trier R1 en  $\frac{10000}{200} = 50$  blocs de 200 pages :  $2P(R2) * On a 50 + 500 > 200$  donc il faut fusionner R2 avant de commencer la jointure oar fusion \* Fusion des blocs de R2 en  $\frac{500}{200} = 3$  blocs :  $2P(R2) * Nombre de blocs : * R1 : 50 blocs * R2 : 3 blocs * \rightarrow 52 < 200$  donc on peut calculer la jointure \* Jointure par fusion :  $P(1) + P(2) * Total : Cout(T) = 3P(R1) + 5P(R2)$

- Transfert de T sur S3 :  $P(T) * t_s = 150000t - S$
- $Cout(Q) ?$  Par hachage externe
  - Lire R3 et répartir en  $\frac{10000}{200} = 50$  blocs :  $2P(R3)$
  - Répartir T (provenant du site S2) en 50 blocs :  $P(T)$
  - Jointure :  $(P(R3) + P(T))t_{IO}$
  - Total :  $(3P(R3) + P(T))t_{IO}$

- Transfert Q :  $P(Q)t_S = 200000t_s$



## Exercice 1 page 12 : Requête réparties avec JDBC

- `SELECT Etu.nom, Stage.lieu FROM Etu, Fait, Stage WHERE Etu.nE = Fait.nE AND Fait.nS = Stage.nS AND Fait.note > 10`
  - Sur S1: `SELECT Etu.nom FROM Etu, Fait WHERE Etu.nE = Fait.nE AND Fait.note > 10`
  - Sur S2: `SELECT lieu FROM Stage`

```
s1 = c1.createStatement();
res1 = s1.executeQuery("SELECT Etu.nom FROM Etu, Fait WHERE Etu.nE = Fait.nE");

p2 = c2.createStatement();
res2 = p2.executeQuery("SELECT lieu FROM Stage s where s.nS=?");

while (res1.next()){
    p2.setInt(1, res1.getInt("nS")); // on remplace le "?" par le Fait.nS
    res2 = p2.executeQuery();
    res2.next() // Faire avancer le curseur d'un tuple ; Résultat unique
    System.out.print(res1.getString("Etu.nom") + res2.getString("lieu"))
}
```

- `SELECT s.lieu, COUNT(*) AS nbEtu FROM Etu e, Stage s WHERE e.résidence = s.lieu AND s.durée = 6 GROUP BY s.lieu HAVING COUNT(*) > 10 ORDER BY lieu ASC`

- Sur S1: `SELECT e.résidence AS nbEtu FROM Etu e`
- Sur S2: `SELECT s.lieu FROM Stage s WHERE s.lieu = ? AND s.durée = 6`

```
SELECT s.lieu FROM Stage s
WHERE s.lieu = ?
AND s.durée = 6
```

```
s1 = c1.createStatement();
res1 = s1.executeQuery("SELECT résidence AS nbEtu FROM Etu");

p2 = c2.createStatement();
res2 = p2.executeQuery("SELECT s.lieu AS nbEtu FROM Stage s WHERE s.lieu = ?");

while (res1.next()){
    p2.setString(1, res1.getString("résidence"));
    res2 = p2.executeQuery();
    res2.next() // Résultat non unique
    if (res2.len() > 10) {
        System.out.print(res1.getString("résidence") + res2.len())
    }
}
```

=> Pratiquement une bonne solution, le `len()` est fait directement dans la requête SQL

### Correction :

```
SELECT s.lieu, COUNT(*) AS nbEtu FROM Etu e, Stage s
WHERE e.résidence = s.lieu
AND s.durée = 6
GROUP BY s.lieu
HAVING COUNT(*) > 10
ORDER BY lieu ASC
```

- Sur S1: `SELECT count(*) AS nbEtu FROM Etu WHERE residence = ?`
- Sur S2: `SELECT * FROM Stage s WHERE s.durée = 6 ORDER BY lieu ASC`
- `s1 = c1.createStatement();`  
`res1 = s1.executeQuery("SELECT count(*) AS nbEtu FROM Etu WHERE residence = ?");`
- `p2 = c2.createStatement();`  
`res2 = p2.executeQuery("SELECT * FROM Stage s WHERE s.durée = 6 ORDER BY lieu ASC");`
- `while (res1.next()){`  
 `r1.setString(1, res2.getString("lieu"));`  
 `res1 = R1.executeQuery();`  
 `res1.next(); // Résultat non unique`  
 `if (res1.getInt("nbEtu") > 10) {`  
 `System.out.print(res2.getString("lieu") + " " + res1.getInt("nbEtu"));`  
 `}`  
`}`

### Autre solution :

```
r1 = "SELECT * FROM (SELECT count(*) AS nbEtu FROM Etu WHERE residence = ?)
WHERE nbEtu > 10" puis test sur le if(){};
```

- Si on commence par S1

```
SELECT e.residence, count(*) AS nbEtu
FROM Etu
GROUP BY residence
HAVING count(*) > 10
ORDER BY residence ASC
```

```
SELECT 1 FROM Stage WHERE Lieu = ? AND durée =6
```

- ```
SELECT s.durée, AVG(f.note) FROM Stage s, Fait f
WHERE s.nS = f.nS
AND s.lieu = "Paris"
GROUP BY s.durée
```

- Sur S1: SELECT SUM(note) as n, COUNT(\*) AS c FROM Fait WHERE nS = ?
- Sur S2: SELECT DISTINCT durée FROM Stage WHERE s.lieu = "Paris"
- et
- SELECT nS FROM Stage WHERE durée = ?
- Obtenir les durée distinct pour Paris
- Pour chaque durée trouver les nS associé
- Pour chaque nS obtenir toute ces notes leurs compte
- Dans l'application fait la moyenne pour chaque durée

- ```
for r1 in R1 :
    Ts = 0
    T_c = 0
    for r2 in R2(R1.durée)
        s,c = R3(r2.nS)
        Ts += s
        Tc += c
    print(r1.durée, Ts/Tc)
```

- ```
SELECT DISTINCT nE FROM Visite v, Fait f, Stage s
WHERE v.nE = f.nE
AND f.nE = s.nE
AND v.ville = "Aix"
AND s.durée >= 3
```

- Sur S1 :

```
SELECT nS FROM Fait
WHERE nE = ?
```

- Sur S2 :

```
SELECT "oui" FROM Stage
WHERE durée = 3 // Toujours le cas
AND nS = ?
```

- Sur S3 : SELECT nE FROM Visite WHERE ville = "Aix"
- Pour chaque nE ayant visité Aix
  - Récupérer sa liste de nS à partir de son nE avec la query sur S1
  - Pour chaque nS :
    - Vérifier si c'est un stage de 3 mois à partir de son nS avec la query sur S2 (if == 'oui')
    - Si oui print son nE et break (évite les doublons)

## TD8

### Exercice 2 page 12 : Requêtes réparties avec JDBC

- Sur S1 : SELECT numA, a1 FROM TA WHERE a2 < 10
  - Sur S2 : SELECT 1 FROM TB WHERE b3 = 9 AND numA = ?
  - Sur S1 : (=r1) SELECT a2 FROM TA
  - Sur S2 : (=r2) SELECT numB, b3, b4 FROM TB WHERE b4 <> ?
  - Sur S3 : (=r3) SELECT c5 FROM TB WHERE numB = ? AND ? < c5
- ```
for a2 in r1:
    for numB, b3, b4 in r2(a2):
        for c5 in r3(numB, b3):
            print(b4, c5)
```

=> Je sais pas si c'est bon perso ça me semble correct, la **correction** inverse les deux première boucle en gros

- Sur S1 : SELECT "ok" FROM TA WHERE a2 = ?
- Sur S2 : SELECT numB, b3, b4 FROM TB
- Sur S3 : SELECT c5 FROM TB WHERE numB = ? AND ? < c5
- ```
for r2 in R2:
    if R1(r2.b4) != 'ok':
        for r2 in R3(r2.numB, r2.b3):
            print(r2.b4, r3.c5)
```

- Méthode de traitement par semi-jointure : ?

#### ◦ Ce qu'il ne faut pas faire

- R1: SELECT num1, a1 FROM TA where a2 = 0
- R2: SELECT b3 FROM TB WHERE b4 = 0 AND numA = ?

- ```
for r1 in R1:
    for r2 in R2(r1.numA):
        print(r1.numA, r1.a1, r2.b3)
```

- **Inconvénient** : L'application lit tous les tuples de r1, y compris ceux qui ne sont pas dans le résultat. Il y a lecture de a1

- Correction : On vas aller chercher a1 uniquement si nécessaire

- R1: SELECT num1 FROM TA where a2 = 0
- R2: SELECT b3 FROM TB WHERE b4 = 0 AND numA = ?
- R3: SELECT a1 FROM TA where numA = ?

```

    ■ for num1 in R1:
        for r2 in R2(numA):
            print(r1.numA, R3(numA), r2.b3)

```

4.
  - Tri fusion : ?
  - R2 : SELECT b4, numB FROM TB ORDER BY b4
  - R3 : SELECT c6, numB FROM TC ORDER BY c6
  - Algo

```

for b4, numB in R2:
    while (b4 > c6):
        r2.next()
    while (b4 == c6):
        print()
        r2.next()

```


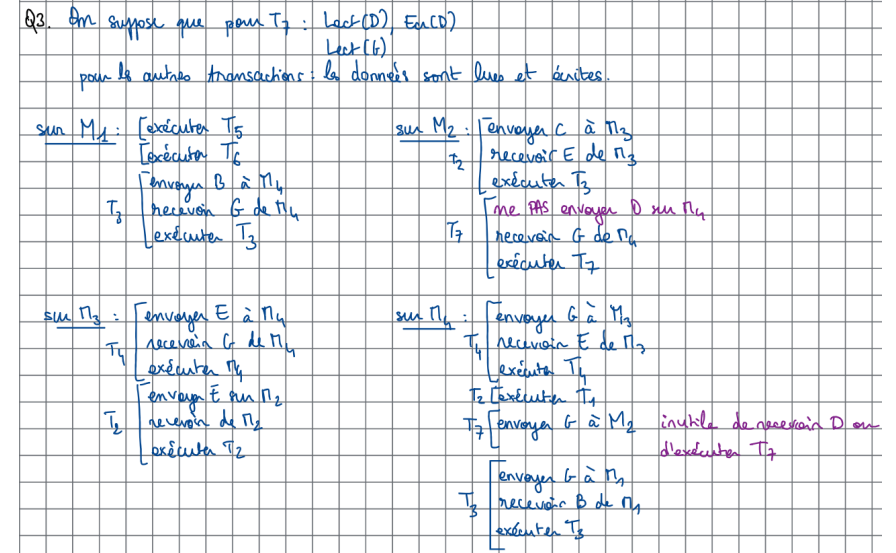
## TD9

### Exercice 1 page 18

1.
  - Indépendant de la machine qui reçoit la transaction
  - Transaction locale :  $T_1, T_5, T_6$  (Transaction pouvant être traité en une machine)
  - Transaction globale :  $T_2, T_3, T_4, T_7$
2.
  1.
    - On considère les transactions reçues sur M1 puis sur M2, M3, M4
      - Sur M1 :
        - T4 sera traité par M3 et M4
        - T5 sera traité par M1
      - Sur M2 :
        - T2 sera traité par M2 et M3
        - T6 sera traité par M1
      - Sur M3 :
        - T1 sera traité par M4
        - T7 sera traité par M2 et M4
      - Sur M4 :
        - T3 sera traité par M1 et M4
    - Finalement on réécrit toutes les transaction sur toutes les machine ( $T_i, M_j$ ) = ( $T_i$  venant de  $M_j$ )
      - M1 : (T5, M1), (T6, M2), (T3, M4)
      - M2 : (T2, M2), (T7, M3)
      - M3 : (T4, M1), (T2, M2)
      - M4 : (T4, M1), (T1, M3), (T7, M3), (T3, M4)
    - Je pense que c'est ordonnée comme demandé dans la consigne, d'abord par rapport à la machine d'origine, si égalité par rapport au numéro de la requête
  2. Pas d'impact dance qu'on a fait avant. Dans M4 on lit juste G. pour T7 sur M4 : lire G et l'envoyer à M2 mais inutile de traiter (lire le code de la transaction) T7 sur M4. (**pas compris**)

3.

### Correction : PAS COMPRIS



### Exercice 10 page 10

Les joueurs sont répartis sur 15 machines en "round-robin" (à tour de rôle)

1.
  - 
  - Sur  $M_i$  : SELECT \* FROM  $J_i$  WHERE salaire = (SELECT max(salaire) FROM  $J_i$ ) envoyer le résultat sur  $M_0$
  - Sur  $M_0$  : Union des résultats reçus des  $M_i$  et sélectionner le joueur avec le max(salaire)