TP3 Coût des accès avec index

Objectifs et contexte du TP Index:

Savoir consulter le catalogue d'une base de données pour connaître la taille d'une table et le domaine de ses attributs.

Savoir définir un index.

Comprendre l'utilisation des index pour évaluer des sélections.

Choix d'une méthode d'accès aux données : accès avec un ou plusieurs index, accès par lecture séquentielle.

Ces notions sont mises en application dans le contexte de la vente de produits où des clients passent des commandes. On s'intéresse aux requêtes couramment posées telles que celles pour connaître les commandes d'un client, d'un produit, et toute autre analyse à laquelle vous pouvez penser.

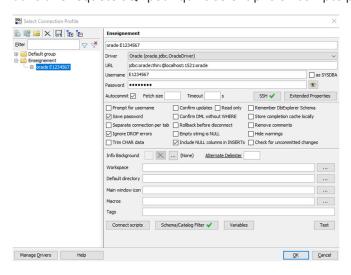
La question générale guidant ce TP est : quels index peut-on définir pour accélérer les requêtes posées ? Pour cela : vous définissez votre base, vos index et montrez qu'ils sont bénéfiques pour les diverses requêtes que vous avez proposées.

Préparation et Questions 1 à 5

A faire AVANT la séance ! Les réponses des questions 1 à 5 sont fournies pour vous permettre de préparer rapidement la base de données.

On utilise Oracle et l'interface SQLWorkbench.

- 1) Commencer par suivre les instructions Oracle avec SQLWorkbench pour installer les outils requis.
- 2) puis vérifier que les options suivantes sont bien cochées : ⊠Autocommit, ⊠Save password, ⊠Ignore DROP errors.
- 3) Vérifier aussi que les case *Separate connection per tab* et *Remove comments* ne sont **PAS** cochées. Il est important de laisser décochée la case Remove comments afin de conserver les commentaires contenus dans une requête SQL pour qu'ils soient pris en compte par Oracle.



Rmq: si vous êtes sur une machine de la PPTI: ajuster le champ URL en conséquence.

3) Compléter la configuration telle que décrite ci-dessous.

Configuration nécessaire pour ce TP:

Accès au catalog

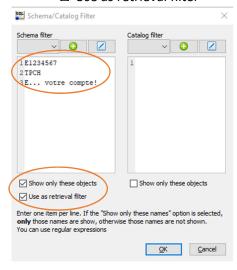
Ajouter un filtre pour explorer plus facilement les tables que vous allez créer et les tables de la base TPCH qu'on utilise dans ce TP :

Dans File → Connect Window, cliquer sur le bouton « Schema/Catalog Filter », cela ouvre la fenêtre suivante, dans laquelle vous compléter la zone *Schema filter* avec deux nouvelles lignes :

- 1. TPCH
- 2. Enuméro, avec numéro étant votre numéro d'étudiant, par exemple E1234567

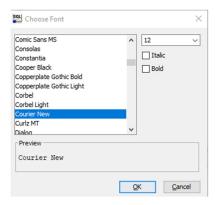
Puis cocher les cases

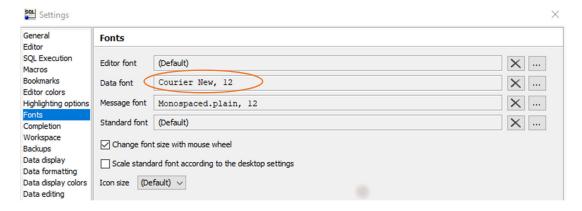
- Show only these objects
- □ Use as retrieval filter



Affichage d'un plan d'exécution

Pour afficher proprement les plans il faut utiliser la police de caractère "Courrier New". Pour cela, aller dans le menu Tools \rightarrow Options \rightarrow Fonts et modifier le champ *Data Font* : cliquer sur le bouton «...» puis, dans la fenêtre *Choose Font*, sélectionner **Courrier** ou **Courrier New**, en taille **12**

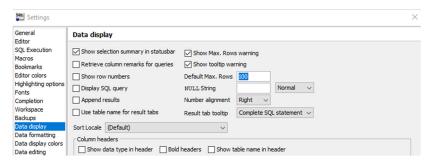




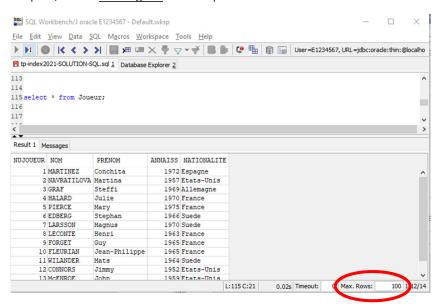
Taille du résultat d'une requête

Limiter la taille du résultat d'une requête à 100 tuples maxi.

Aller dans Tools → Options → Data Display. Puis fixer la valeur de Default Max Rows à 100.



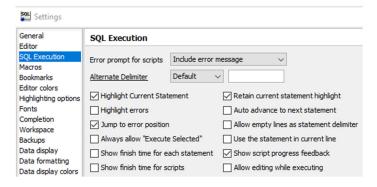
De plus, il faut renseigner le champ Max. Rows dans la barre inférieure de la fenêtre principale : saisir 100



Mettre en évidence la requête en cours d'exécution

Aller dans Tools \rightarrow Options \rightarrow SQL Execution. Puis

- cocher les cases : ⊠Highlight current statement, ⊠ Retain current statement, ⊠ Jump to error position, ⊠ show script progress feedback
- Décocher toutes les autres cases



Charger les macros:

Dans ce TP, nous étudions les plans d'exécution des requêtes. Avec SQL Workbench, il est possible d'afficher facilement le plan d'une requête à l'aide des touches F2 et F3 associées à des macros. Pour cela, il suffit de charger le fichier WbMacros-optimize.xml dans le menu Macros → Load Macros. Puis choisir le fichier WbMacros-optimize.xml qui se trouve dans le dossier du TP.

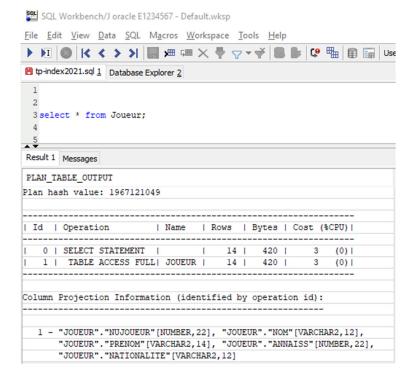


Vérifier le bon fonctionnement des macros :

Saisir une requête simple pour tester l'affichage de son plan, par exemple :

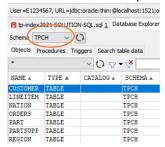
Select * from Joueur;

Positionner le curseur sur une ligne de la requête et presser la touche F2, cela doit afficher le plan suivant :



Données utilisées.

On considère une application de vente de produits. Les données sont issues du benchmark TPC-H. Voir le schéma des données (fichier TPCH_schema.pdf) ou voir le schéma TPCH dans le database Explorer.



Afficher la taille en nombre de pages et la cardinalité de chaque table :

```
select table_name, blocks, num_rows, avg_row_len, global_stats, user_stats
from all_tables
where owner = upper('tpch') and not(table_name like 'S%')
order by num_rows desc;
```

TABLE_NAME	BLOCKS	NUM_ROWS	AVG_ROW_LEN
LINEITEM	109037	6001215	125
ORDERS	24377	1500000	110
PARTSUPP	17237	800000	142
PART	3898	200000	132
CUSTOMER	3520	150000	159
NATION	5	25	102
REGION	5	5	97

Question 1:

- a) Quelle la plus grande table et quelle est sa cardinalité?
- b) Sur combien de pages (ou blocs) cette table est-elle stockée?
- c) Définir des synonymes vers les tables de la base TPCH

```
create or replace synonym Orders for tpch.Orders;
create or replace synonym Lineitem for tpch.Lineitem;
CREATE OR REPLACE SYNONYM PART FOR tpch.PART;
CREATE OR REPLACE SYNONYM PARTSUPP FOR tpch.PARTSUPP;
CREATE OR REPLACE SYNONYM CUSTOMER FOR tpch.CUSTOMER;
CREATE OR REPLACE SYNONYM NATION FOR tpch.NATION;
CREATE OR REPLACE SYNONYM REGION FOR tpch.REGION;
```

Question 2 : Définir la table Commande à partir de la table Orders

Insérer les commandes du 1^{er} trimestre 1992 (pour les mois allant de 1 à 3)

```
insert into Commande (
    select
    o_orderkey as numCde,
```

```
o_custkey as numClient,
o_orderstatus as etat,
o_totalprice as prixC,
o_orderdate as dateC,
o_orderpriority as priorite,
o_clerk as vendeur,
o_comment as commentaire
from Orders
where extract(year from o_orderdate) = 1992
and extract(month from o_orderdate) between 1 and 3
);
```

Question 3: table AchatProduit

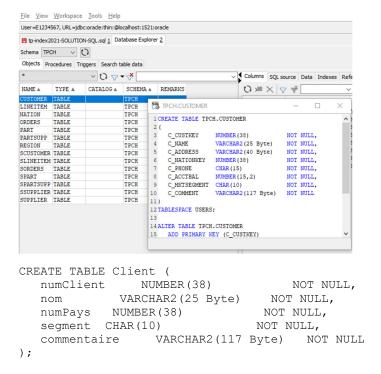
a) Définir la table AchatProduit à partir de la table LineItem

```
drop table AchatProduit cascade constraints purge;
create table AchatProduit (
      numCde
                          Number
                                        not null,
      numAchat
                                       not null,
                          Number
      dateAchat
                                       not null,
                         Date
                         Number (15,2) not null,
      prix
                         Number (15,2) not null,
      Number
numFournisseur Number
commentaire
      guantite
                                       not null,
                                       not null,
                         varchar2 (100)
);
```

b) Insérer les Achats correspondant aux commandes existant dans la table Commande. Indications : le numéro d'acaht est L_LINENUMBER, la date est L_COMMITDATE, le prix est L_EXTENDEDPRICE, le numéo du produit est L_PARTKEY. Ne pas oublier la jointure avec Commande.

Question 4 : Définir vos propres tables à partir des autres tables de cette base.

a) Définir **Client** (numClient, nom, numPays, segment, commentaire) à partir de Customer. Indications : s'inspirer de l'instruction de création de la table Customer. Dans Database Explorer, sélectionner la table Customer, puis clic droit, menu contextuel « create DDL script ». Le segment est C MKTSEGMENT.



b) Insérer dans Client ceux dont le numéro figure dans la table Commande. Ne pas insérer plusieurs fois un même client qui a passé plusieurs commandes. Vérifier qu'il y a 42427 Clients.

```
INSERT INTO Client(
   SELECT DISTINCT c.C_CUSTKEY AS numClient,
   c.C_NAME AS nom,
   c.C_NATIONKEY AS numPays,
   c.C_MKTSEGMENT AS segment,
   c.C_COMMENT AS commentaire
   FROM Customer c, Commande co
   WHERE co.numClient = c.C_CUSTKEY
);
```

c) Définir **Produit** (numProduit, nom, marque, type, taille, prixDetail) à partir de Part. Indications : la marque est P BRAND.

```
CREATE TABLE Produit
                  NUMBER (38)
                                       NOT NULL,
  numProduit
             VARCHAR2 (55 Byte) NOT NULL,
  nom
               CHAR (10)
                                   NOT NULL,
  marque
               VARCHAKZ (25 L,

NUMBER (38)

NOT NULL
               VARCHAR2 (25 Byte)
                                  NOT NULL,
  type
                                    NOT NULL,
  taille
  prixDetail NUMBER(15,2)
);
```

d) Insérer les produits correspondant aux produits achetés dans AchatProduit. Ne pas insérer de produits en double, même s'ils correspondent à plusieurs achats. Vérifier qu'il y a 135 775 produits.

```
INSERT INTO Produit(
   SELECT DISTINCT p.P_PARTKEY AS numProduit,
   p.P_NAME AS nom,
   p.P_BRAND AS marque,
   p.P_TYPE AS type,
   p.P_SIZE AS taille,
   p.P_RETAILPRICE AS prixDetail
   FROM PART p, AchatProduit a
   WHERE a.numProduit = p.P_PARTKEY
);
```

Question 5. Statistiques sur les tables

Créer une procédure *analyse*(*nomtable*) qui collecte des statistiques sur une table : cardinalité, taille et domaine de chaque attribut. Un domaine peut être décrit

- de manière succincte par ses bornes min et max
- ou de manière plus complète par un histogramme.

On remarque que les bornes min max sont un cas particulier d'histogramme de taille 1. Commencer par utiliser les options

```
method_opt => 'for all columns size 1' pour collecter seulement les bornes min et max
estimate_percent => 100
```

Puis ultérieurement (après la séance), vous pourrez modifier la procédure *analyse* pour collecter des histogrammes.

Invoguer cette procédure sur les tables que vous avez créées.

```
exec analyse('COMMANDE');
exec analyse('ACHATPRODUIT');
exec analyse('CLIENT');
exec analyse('PRODUIT');
```

Cela affiche: analyse executed successfully

Les statistiques sont consultables en interrogeant les vues user_tables et user_tab_columns comme ceci :

Afficher pour chaque table sa cardinalité et son nombre de pages

```
select table_name,
    num_rows as card,
    blocks as pages,
    global_stats as analyseFaite
from user_tables;
```

Afficher, pour chaque attribut de chaque table, les bornes min et max de son domaine ainsi que le nombre de valeurs distinctes.

```
select table_name, column_name, data_type, sample_size,
 num distinct as nb distinct, -- cette valeur est une approximation
 null,
 null
from user tab columns c
where data_type like '%CHAR%' or data_type = 'DATE'
and table name in ('ACHATPRODUIT', 'COMMANDE', 'CLIENT', 'PRODUIT')
order by table name, column name;
select table_name, column_name, data_type, num_distinct, sample_size,
      avg col len as longueur moyenne,
      utl raw.cast to number(low value) as borneInf,
      utl raw.cast to number (high value) AS borneSup,
      density
from user tab columns c
where data type = 'NUMBER'
order by table_name, column_id;
select table name, column name, data type, num distinct,
      avg_col_len as longueur_moyenne,
      null as borneInf, null AS borneSup,
      density
from user_tab_columns c
where data type = 'DATE' or data type like '%CHAR%'
order by table name, column name;
```

Combien y a-t-il de dates et de prix différents pour les commandes ?

Combien y a-t-il de quantités distinctes pour les achats d'un produit ?

Index et requêtes

Question 6 Index simples

Créer un index sur chaque attribut d'une ligne de commande dans la table Achat Produit.

```
drop index I_Achat_quantite;
create index I_Achat_quantite on AchatProduit(quantite);
drop index I_Achat_prix;
create index I_Achat_prix on AchatProduit(prix);
drop index I_Achat_numCde;
create index I_Achat_numCde on AchatProduit(numCde);
etc...
```

Afficher les statistiques sur les index en interrogeant la vue user indexes

```
SELECT index_name as nom,
    index_type as type_index,
    blevel as profondeur,
    distinct_keys as nb_valeurs_distinctes,
    num_rows as nb_rowids,
    leaf_blocks as nb_pages_de_rowids,
    uniqueness as unicite,
    clustering_factor as CF

FROM user_indexes;
```

Quel index a la plus grande profondeur?

Quel index a le plus grand nombre de pages de rowid?

Question 7. Requêtes avec index simple

Pour chaque requête afficher son plan (touche F2).

Préciser les méthodes d'accès utilisées parmi les méthodes suivantes :

```
INDEX RANGE SCAN, INDEX UNIQUE SCAN, INDEX FULL SCAN, INDEX SKIP SCAN
```

et quel prédicat est évalué par l'index ;

Préciser si l'opération TABLE ACCESS BY INDEX **ROWID** est nécessaire après avoir lu l'index et quel prédicat est évalué par filtrage (*filter*) pendant cette opération.

a) Quels sont les produits achetés à moins de 2000 euros ?

```
SELECT /*+ index(a I_achat_prix) */
   *
FROM AchatProduit a
WHERE prix < 2000;</pre>
```

b) Quels produits sont achetés en grande quantité (quantité supérieure à 40) ?

```
SELECT /*+ index(a I_achat_quantite) */
    *
FROM AchatProduit a
WHERE quantite > 40;
```

c) Lister toutes les valeurs des prix des achats

```
SELECT /*+ index(a I_achat_prix) */
    prix
FROM AchatProduit a;
```

d) Le numCde et numAchat des achats en quantité > 40 et dont le prix < 2000 : proposer une solution avec l'index sur la quantité puis une autre avec l'index sur le prix

...

e) Même requête mais en combinant l'utilisation des deux index sur le prix et la quantité

```
SELECT /*+ index_combine(a I_achat_prix I_achat_quantite) */
    numCde, numAchat
FROM AchatProduit a
WHERE prix < 2000 and quantite > 40;
```

f) Même requête mais en demandant l'utilisation conjointe de tous les index possibles.

```
SELECT /*+ index_join(a I_achat_prix I_achat_quantite) */
```

```
numCde, numAchat
FROM AchatProduit a
WHERE prix < 2000 and quantite > 40;
```

Comparer les plans d'exécution pour deux situations différentes lorsque les index existants sont :

- I_achat_prix, I_achat_quantite, I_achat_numCde
- I_achat_prix, I_achat_quantite, I_achat_numCde et I_achat_numAchat

Dans quelle situation peut-on dire que les index <u>couvrent</u> la requête ?

Question 8. Requêtes avec index composé

Créer un index sur les attributs quantité et prix

```
drop index I_Achat_quantite_prix;
create index I_Achat_quantite_prix on AchatProduit(quantite, prix);
```

Expliquer l'utilisation d l'index pour les requêtes :

- a) prix < 1000 and quantite =2
- b) quantite = 2
- c) prix < 1000
- d) prix > 1000

Question 9 : Coût de l'opération INDEX RANGE SCAN

On rappelle qu'on connaît pour un index sa profondeur, son nombre total de rowids et le nombre de pages contenant ces rowids :

```
SELECT index_name as nom,
    index_type as type_index,
    blevel as profondeur,
    num_rows,
    leaf_blocks as nb_pages_de_rowids
FROM user indexes;
```

Le coût de l'opération INDEX RANGE SCAN représente le nombre de lectures pour traverser l'index et sélectionner les rowids contenus dans les feuilles de l'index. Soit n le nombre de rowids sélectionnés dans l'index. La valeur de n est indiquée dans le plan de la requête : c'est le champ ROWS de l'operation INDEX RANGE SCAN. On a :

```
Cost_Index_Range_Scan(n) = (blevel-1) + n * leaf_blocks / num_rows
```

Autre formulation équivalente :

```
Cost_Index_Range_Scan(predicat) = (blevel-1) + leaf_blocks * SF(p) avec SF(p) étant le facteur de sélectivité du prédicat évalué par l'index
```

Appliquer cette formule aux requêtes « simples » vues ci-dessus (question 7)

Question 10 : Coût de l'opération TABLE ACCESS BY ROWID

Soit la requête interrogeant les statistiques des indexes :

Le clustering_factor (CF) correspond au nombre de lectures à effectuer pour lire num_rows tuples qui ont des valeurs consécutives pour l'attribut indexé. Sa valeur est comprise dans [blocks, num_rows] c'est-à-dire dans [nombre de pages de la table, cardinalité de la table].

CF permet d'estimer le nombre de lectures déclenchées par l'opération TABLE ACCESS BY ROWID. On a :

```
Cost_table_Access_By_Rowid(n) = Cost_Index_Range_Scan(n) + n * CF / num rows
```

a) Pour quel index a-t-on CF très proche de num rows?

Pour quel index a-t-on CF très inférieur à num rows?

D'après vous, quelle particularité dans l'insertion des commandes et des achats a pour effet de diminuer le CF d'un index sur l'attribut numCde ?

b) Pour les requêtes proposées ci-dessus et dont le plan utilise un index, appliquez la formule de coût Cost_table_Access_By_Rowid et vérifiez que vous retrouvez approximativement le coût estimé par le SGBD.

Question 11 Cardinalité d'une requête

On veut déterminer la cardinalité d'une requête de type : BETWEEN v1 AND v2

Soit la table T et l'attribut ATT qui est de type Number. On dispose des informations suivantes :

On suppose que v1 et v2 sont inclus dans [borneInf, borneSup]. On a la formule :

```
cardSelection(T, ATT, V1, V2) = (V2 - V1) / (borneSup - borneInf) * num rows
```

- a) Appliquer cette formule aux requêtes « simples » vues ci-dessus, en faisant attention de choisir des valeurs v1 et v2 <u>dans</u> l'intervalle [borneInf, borneSup].
- b) Définir la fonction cardSelection(T, ATT, v1, v2) qui retourne la cardinalité d'une requête

```
Select * from T where ATT between V1 and V2
```

Indication: create or replace function cardSelection(...., ..., ...) return number as ...

Question 12 : Requête un attribut unique ou clé primaire

Modifier la table Commande : définir la clé primaire étant l'attribut numCde

```
alter table Commande add constraint cle commande primary key(numCde);
```

- a) Est-ce que cela a déclenché la création de l'index CLE_COMMANDE ? Si oui, afficher les caractéristiques de cet index.
- b) Expliquer la méthode INDEX UNIQUE SCAN utilisée dans la requête :

```
SELECT /*+ index(a cle_commande) */
    *
FROM Commande a
WHERE numCde = 200 ;
```

Question 13: Requêtes avec tri: ORDER BY

Montrer que l'utilisation de l'index est utile pour les requêtes de type : ORDER BY

a) Quel est le coût de l'opération INDEX FULL SCAN dans la requête suivante ?

```
select prix
from AchatProduit
order by prix;
```

b) Quel est le coût de l'opération INDEX FAST FULL SCAN dans la requête suivante ?

```
select distinct prix
from AchatProduit
order by prix;
```

c) Pourquoi l'opération fast full scan provoque-t-elle moins de lectures que full scan ?

Question 14 : Requête avec agrégation min max

a) Expliquer la méthode d'accès INDEX FULL SCAN (MIN/MAX) utilisées dans la requête

```
select min(prix)
from AchatProduit;
select max(prix)
from AchatProduit;
```

b) Est-ce que cette méthode est utilisée pour une requête avec 2 agrégations et pourquoi?

```
select min(prix), max(prix)
from AchatProduit;
```

Question 15 : Coût d'une opération TABLE ACCESS FULL

Le coût de la lecture séquentielle d'une table est la somme de deux termes :

```
coût_lecture_sequentielle(T) = pages(T) / multiRead + card(T) / cpu
avec multiRead = 3,77 et cpu = 58000
```

Le terme principal représente le nombre de lectures multi-pages, il dépend du nombre de pages.

Le terme minoritaire représente le coût CPU et dépend de la cardinalité.

On rappelle la requête donnant les valeurs de pages et card :

```
select blocks as pages, num_rows as card
from user_tables
```

Exemple, pour AchatProduit on a pages(AchatProduit) = 2119 et card(AchatProduit) = 226736

Le coût TABLE ACCESS FULL de AchatProduit est :

coût_lecture_sequentielle(AchatProduit) = ceil(2119/3,77) + ceil(226736/58000) = 567

Appliquer la formule aux autres tables de votre base.

Divers et questions fréquentes:

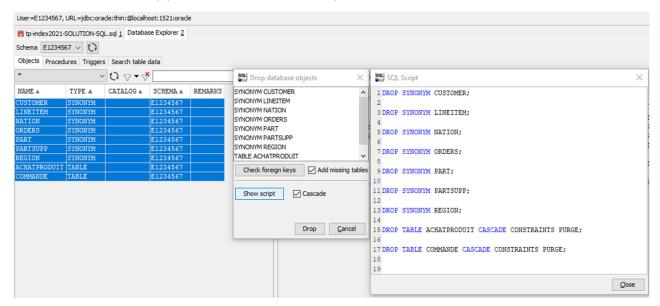
Comment stopper l'exécution d'une requête?

→ Cliquer sur le bouton rouge



Comment supprimer tout le contenu de mon compte oracle (table, type, synonyme, ...)?

→ Dans Database Explorer, sélectionner tous vos objets (sauf les table qui sont en fait des « sous tables » ou nested tables car elles sont supprimées automatiquement quand on supprime la table qui les contient), puis passer la souris sur la zone sélectionnée et bouton droit menu contextuel drop, cocher cascade et bouton Drop.Le bouton « Show script » vous permet de générer les instructions drop pour les réutiliser automatiquement.



La touche F2 produit l'erreur "The macro uses current statement no text is selected"?

→ Placer le curseur en début de requête avant d'appuyer sur F2.

Les directive d'optimisation ne sont **jamais** prises en compte?

→ Vérifier que la case « Remove Comments » n'est **PAS** cochée dans la fenêtre « Connection Profile »